ETEVERS

Challenge for Transformation!

AI-Ready Data Center

CISCO

2026.03

AI는 기술이 아니라 비즈니스 성과를 만드는 수단

매출 증대와 비즈니스 성장 가속	비용 절감과 운영 효율 극대화	고객 및 직원 경험의 개선

- Knowledgebase AI Assistants
- Content and code generation
- Virtual agent and chatbots
- Visual Analytics
- Language translation
- Detection and prediction

AI 프로젝트의 Challenges: 가치 실현까지의 시간 단축

보안 취약점

AI 모델, 프레임워크, 앱 및 지원 인프라는 새로운 사이버 공격 대상

네트워크 성능 병목

모델 학습 및 추론에서 발생되는 많은 트래픽은 네트워크 속도를 저하로 시켜 프로젝트 지연

복잡한 AI 인프라

컴퓨팅, 네트워크, 스토리지, AI 소프트웨어가 통합된 고성능 인프라가 부족해서 오는 지연

Cisco Secure AI Factory의 요소

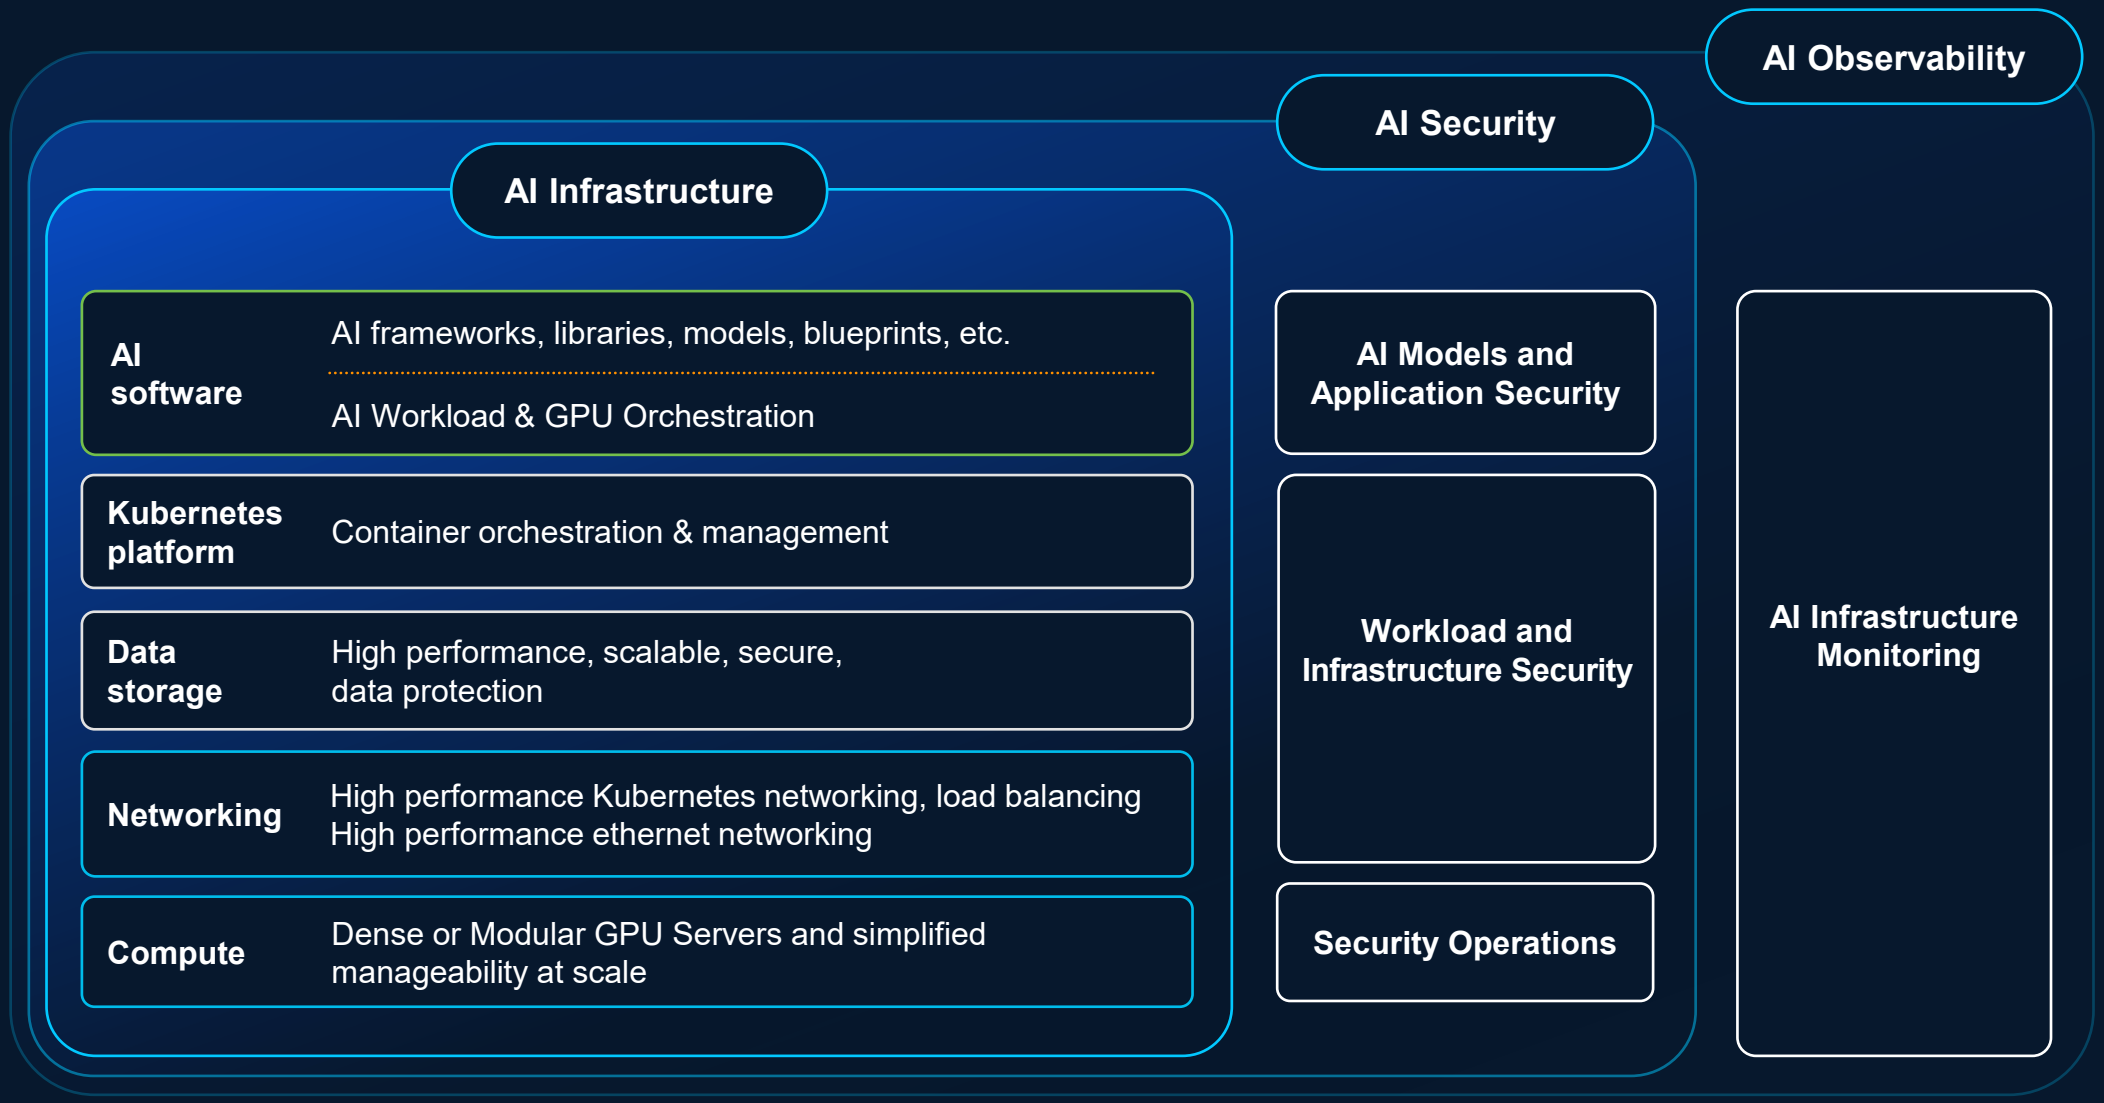

Cisco Secure AI Factory 포트폴리오

Cisco AI PODs

NVIDIA AI Enterprise — NeMo | NIM | Blueprints

NVIDIA Run:ai — AI Workload & GPU Orchestration

Kubernetes platform	Options: Red Hat OpenShift, Nutanix NKP, Upstream Kubernetes
Partner storage	Options: NetApp, Pure Storage, VAST Data, Hitachi Vantara, Nutanix NUS
Cisco AI Networking	Cisco Data Center Switching Options for Network Management: Nexus Dashboard or Nexus Hyperfabric — NVIDIA Partnership
Cisco Compute	Options: NVIDIA HGX, MGX or RTX PRO based UCS Servers NVIDIA BlueField® DPUs | Managed with Cisco Intersight®

AI Security

- Cisco AI Defense
- Smart Switch with Hypershield
- Live Protect
- Splunk Enterprise Security

AI Observability

- Splunk Observability

AI Compute

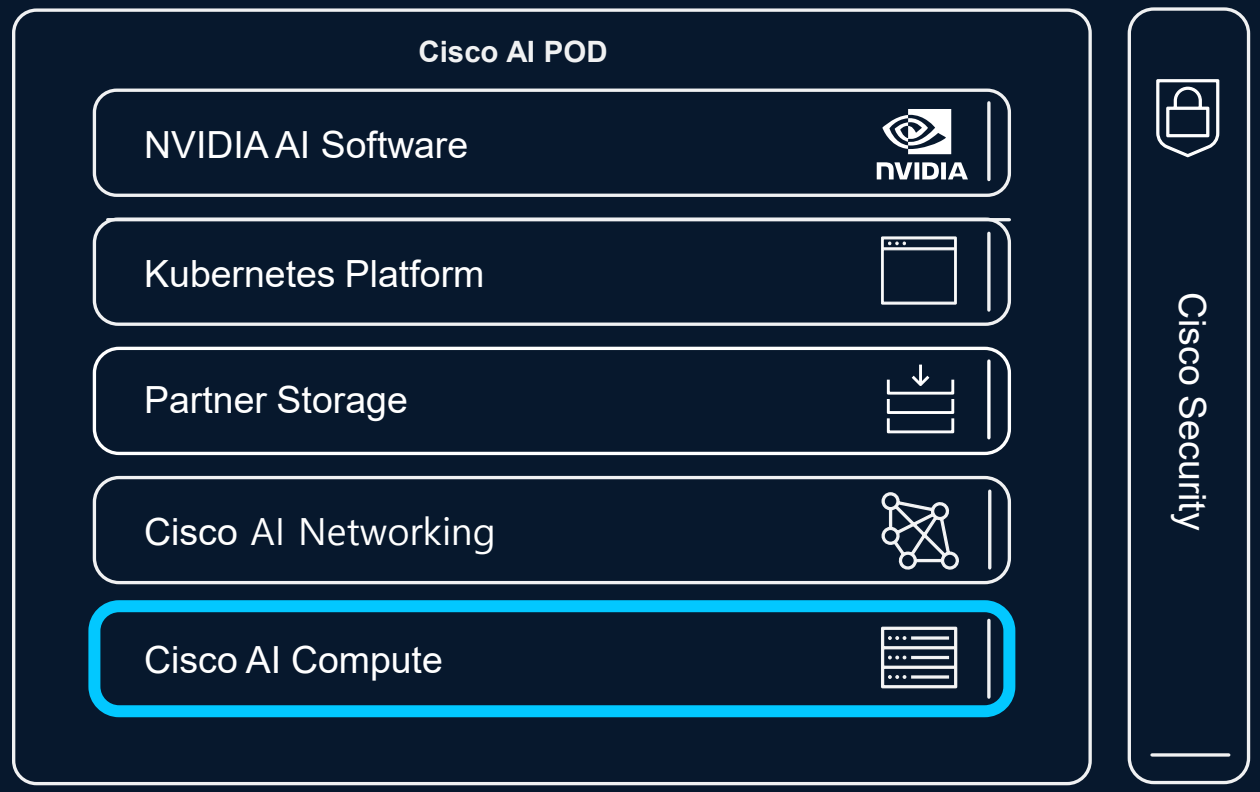
Cisco AI POD
NVIDIA AI Software
NVIDIA
Kubernetes Platform
Partner Storage
Cisco AI Networking
Cisco AI Compute
Cisco Security

Training, fine-tuning, inferencing and RAG

새로운 모델 개발
Custom Foundation Model

완성된 모델 수정 및 최적화
Fine-tuning and RAG

완성된 모델 소비
Pretrained model + Inferencing

Training

모델을 처음부터 만드는 작업

아주 큰 데이터셋을 이용해 모델의 파라미터를 처음부터 학습시키는 과정

Fine-tuning

이미 만들어진 모델을 우리 용도로 맞추는 작업

Fine-tuning은 기존에 학습된 모델을 기반으로 기업 데이터나 특정 업무에 맞게 조정하는 과정

RAG(Retrieval-Augmented Generation)

모델이 답변을 생성하기 전, 외부 신뢰할 수 있는 지식 기반(사내 문서, 데이터베이스 등)에서 관련 정보를 검색하여 그 내용을 바탕으로 답변을 보강하는 기술

Inferencing

모델을 실제로 사용하는 단계

Inferencing은 사용자의 요청(prompt)을 받아 모델이 답을 생성하는 과정

LLM을 도입하는 고객의 스펙트럼

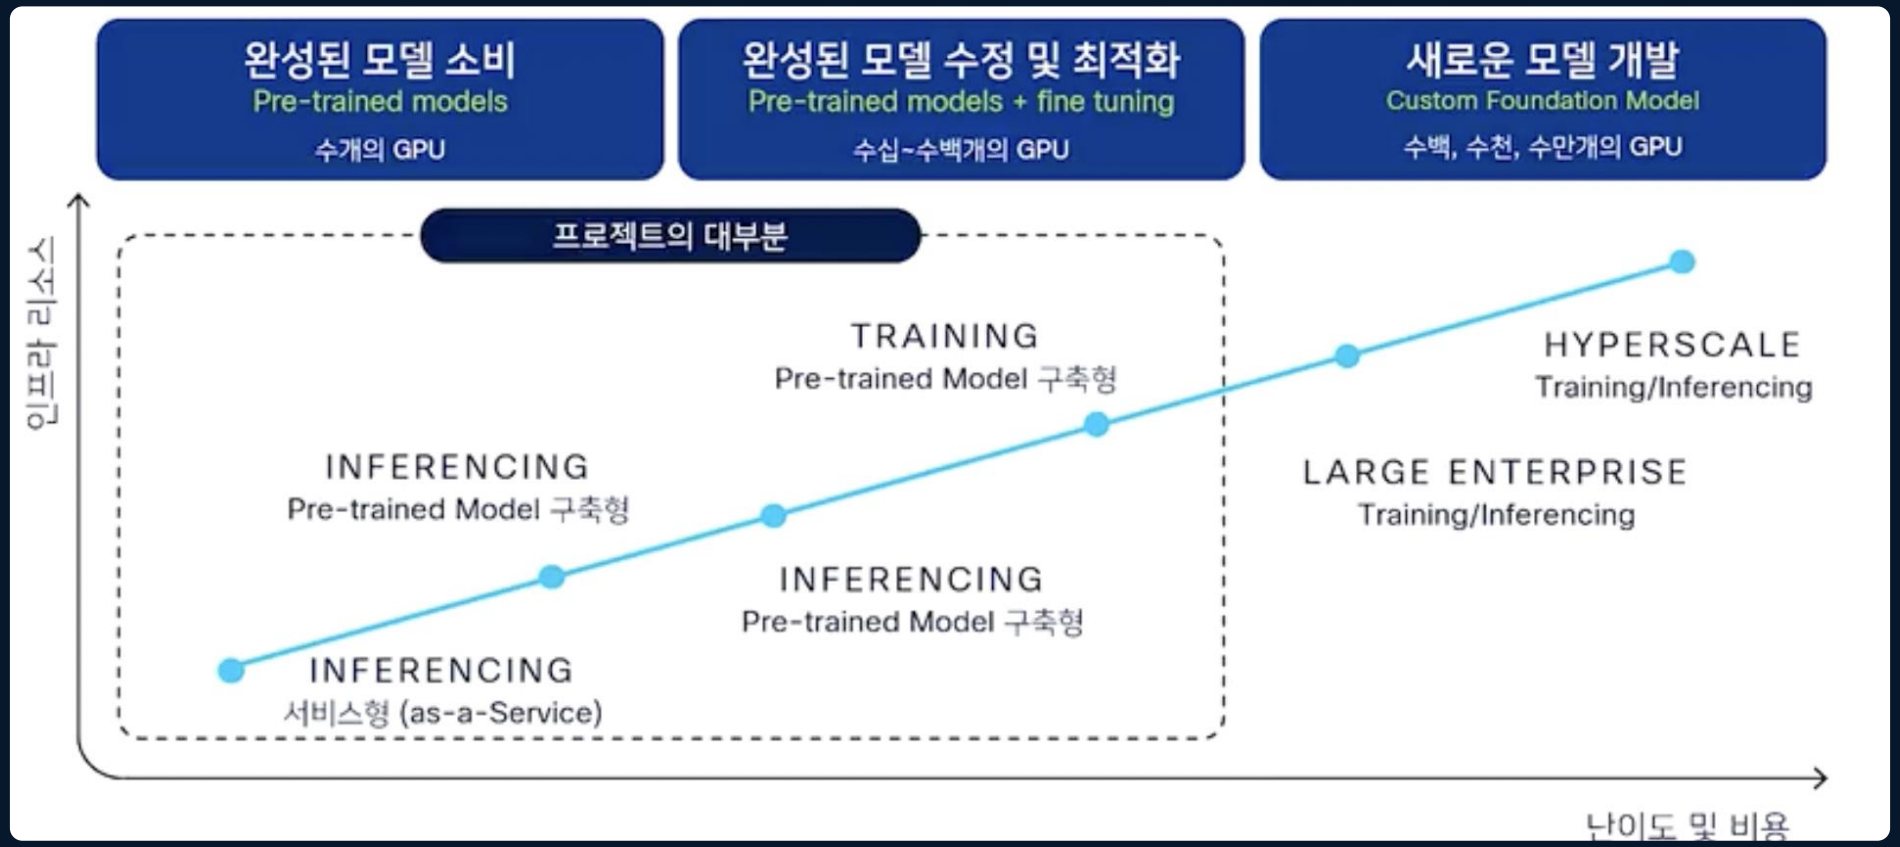

Cisco AI Compute 포트폴리오

모델 크기와 고객 환경에 맞게 선택할 수 있는 다양한 포트폴리오

새로운 모델 개발
Custom Foundation Model

완성된 모델 수정 및 최적화
Fine-tuning and RAG

완성된 모델 소비
Pretrained model + Inferencing

Cisco UCS®
GPU-dense servers
PCIe and NVLink Servers

Cisco UCS blade (with GPU extensions)
and rack servers

Enterprise AI edge

ETEVERS

High-Density Hopper GPU Server for in Cisco UCS Family

For data-intensive use cases like model training and deep learning

UCS ACCELERATED | CISCO UCS C885A

NVIDIA HGX™ reference design

Supporting 8 NVIDIA HGX™ H100, H200 and NVIDIA AI Enterprise software

And 2 AMD 4th Gen/5th Gen EPYC Processors

High-Density Blackwell GPU Server for in Cisco UCS Family

Built for LLM training, deep learning, fine-tuning, and HPC

UCS Accelerated | UCS C880A M8 NEW AVAILABLE NOW

2 CPUs
Intel Xeon 6th Gen Scalable Processor

NVIDIA HGX with 8 GPUs
NVIDIA B300 with NVL8 Air Cooled

Network
(8) NVIDIA ConnectX-8 GPU Board Integrated (E-W)
(2) NVIDIA BF3 B3220, NVIDIA BF3240, NVIDIA ConnectX-7 (N-S)

Power
(12) 50V 3200W (N+N redundancy)

Flexible, modular AI servers

"Start small and scale up" with AI

UCS ACCELERATED | CISCO UCS C845A

NVIDIA MGX™ reference design

With NVIDIA H100, H200, L40S, AMD MI210 GPUs

Included as an option in Nexus Hyperfabric AI

High performance in a compact form factor

Enhanced power delivery, fewer PCBs, and better cable routing for optimal airflow and thermal management

with NVIDIA RTX PRO 6000 Blackwell GPUs
[orderable now]

중앙 Data Center

On-Premise Edge

	2021	2027
Data Center	90%	25%
On-Premise Edge	10%	75%

AI로 인해 로컬 데이터 처리와 네트워킹에 대한 수요가 증가

Cisco Unified Edge

Compute | Storage | Networking | Software | SaaS Management | Analytics | Security

NUTANIX | Red Hat | vmware by Broadcom | Canonical Ubuntu | Microsoft | intel. | cisco | SUSE

AI Networking

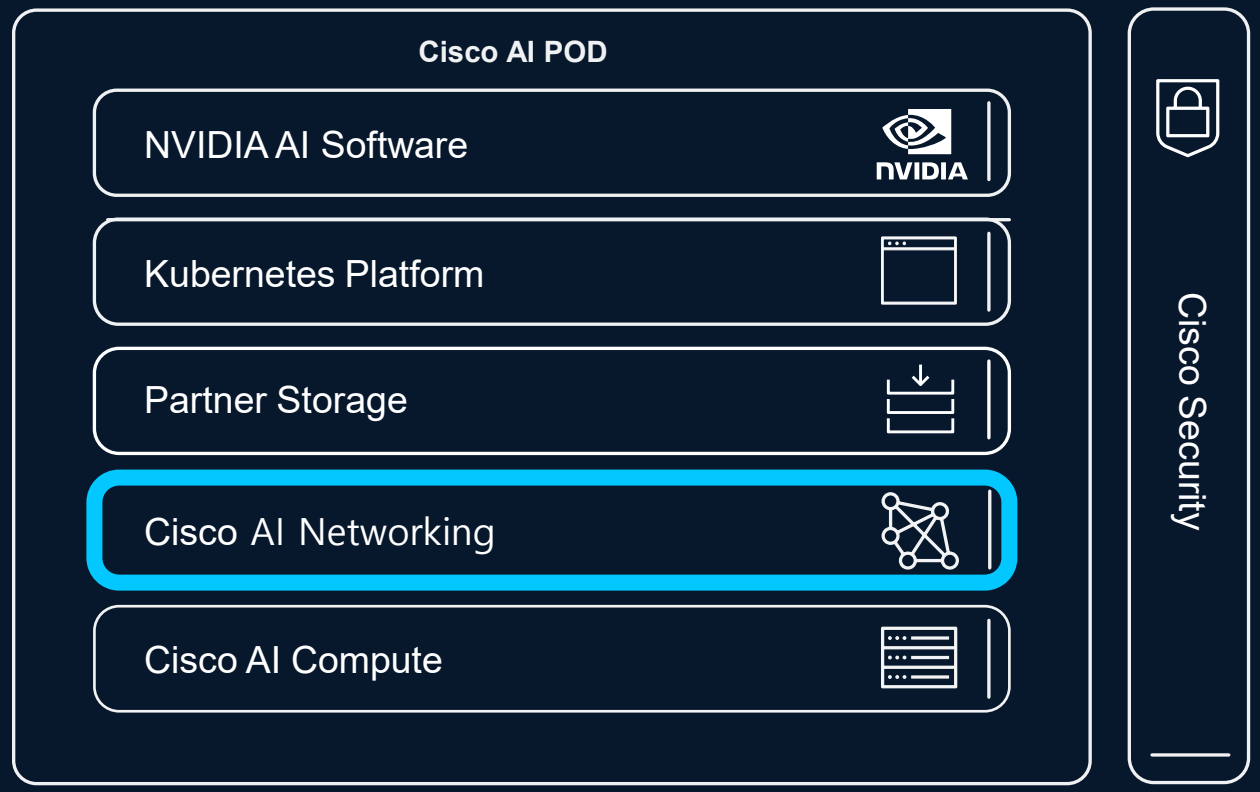

AI Network의 구조

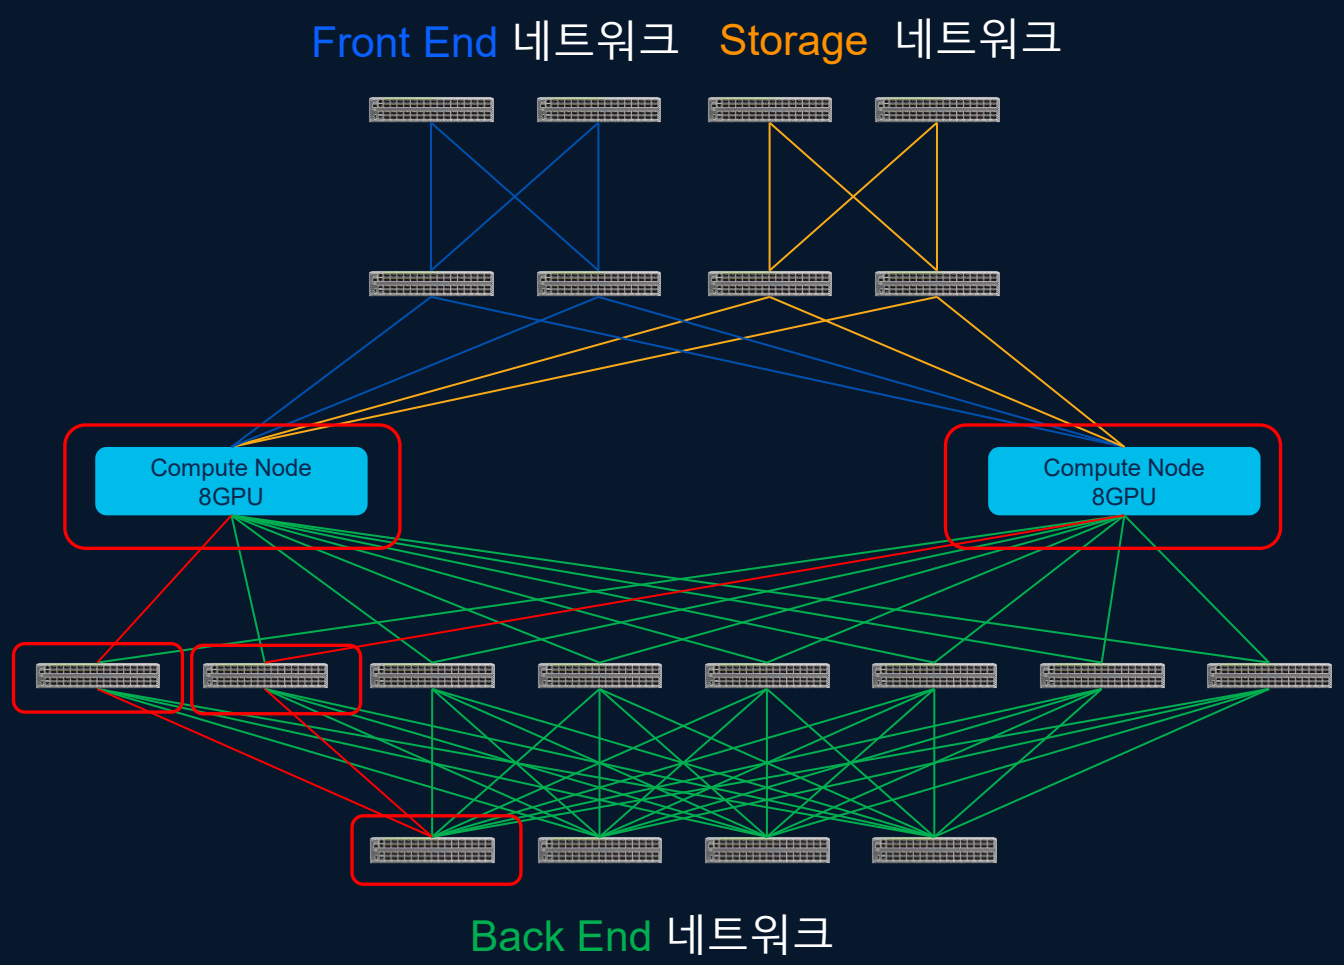

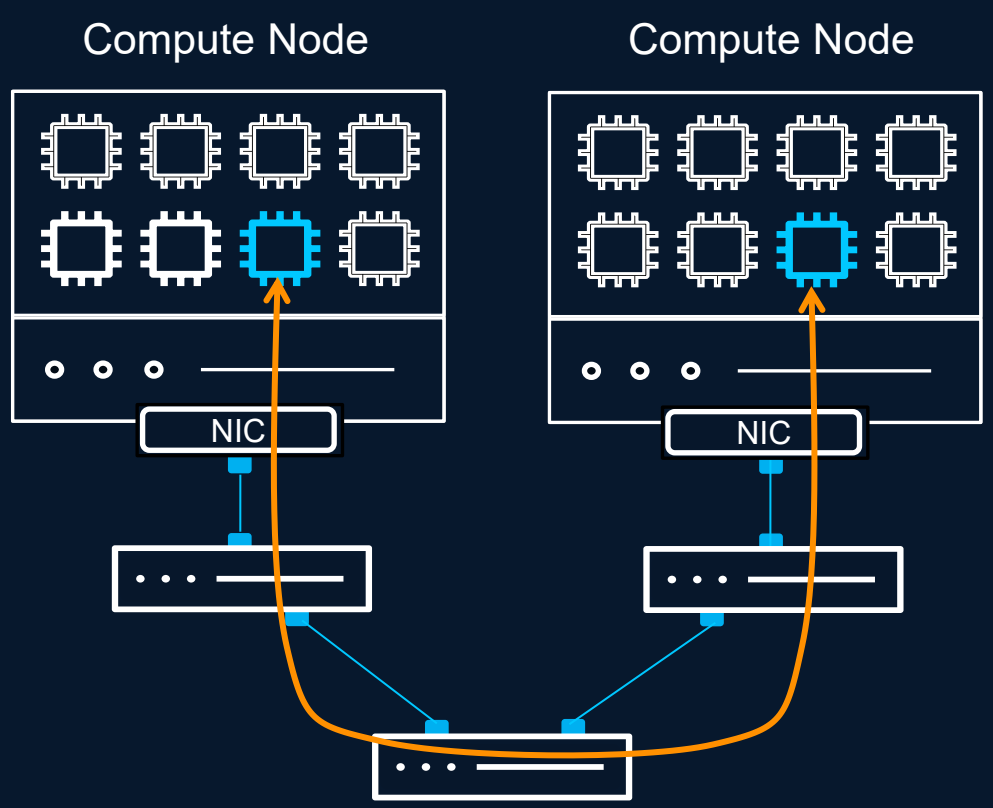

모델링을 작성하고 추론을 수행하며 분석을 수행하는 Network

AI Training에서 GPU Cluster의 트래픽 플로우

AI Training Process 요약

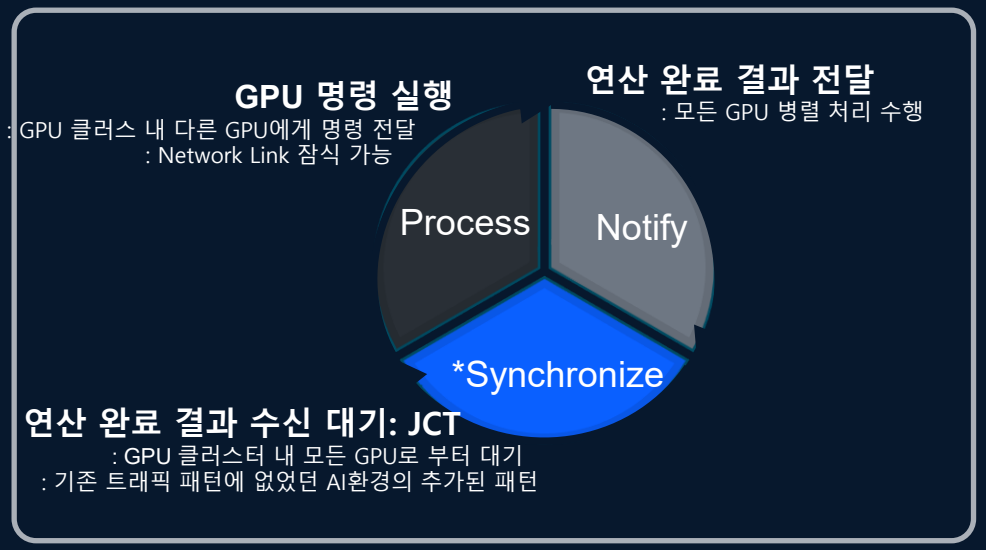

정확한 모델의 학습을 위해 위 프로세스를 수 차례 반복

GPU Cluster의 Ring Topology 트래픽 플로우

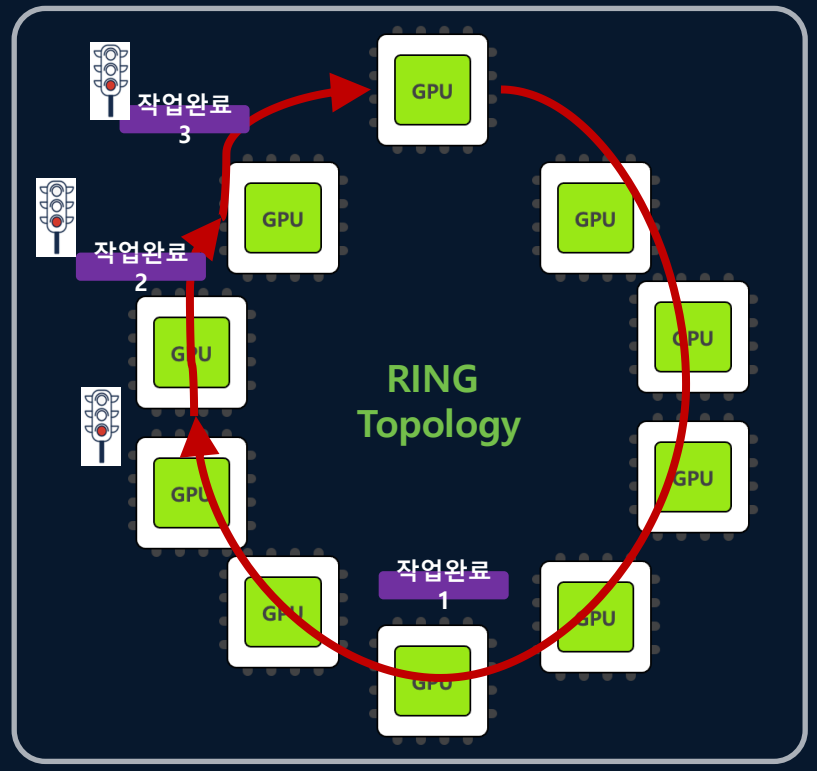

AI Training에서 GPU Cluster의 트래픽 플로우

GPU Cluster의 Ring Topology 트래픽 플로우

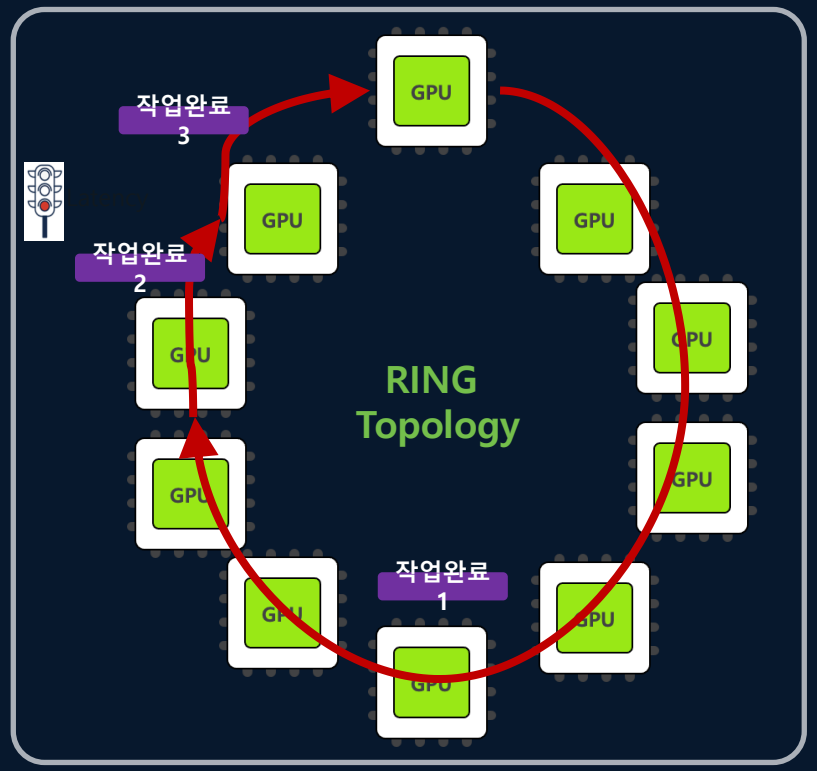

GPU Cluster에서 발생하는 Latency 이해

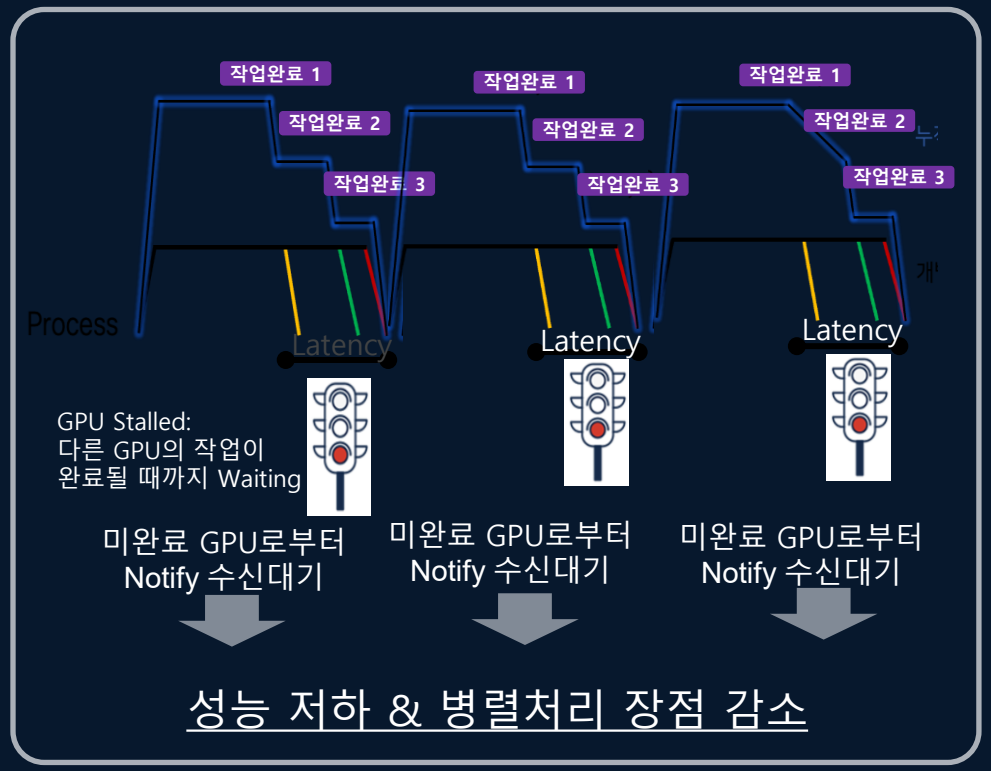

AI Network 요구 사항

Non-Blocking, High Bandwidth

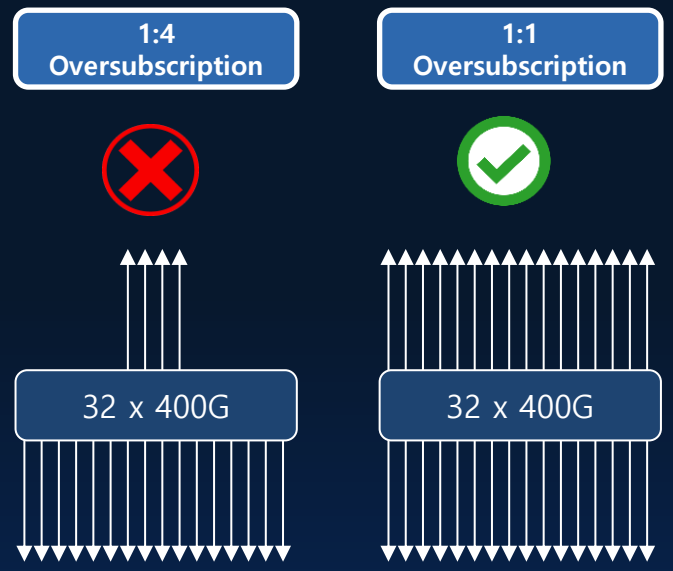

400/800G 기반의 non blocking network을 만들어 물리적으로 네트워크 병목이 생기지 않도록 구성

Low Latency & Lossless

RoCEv2

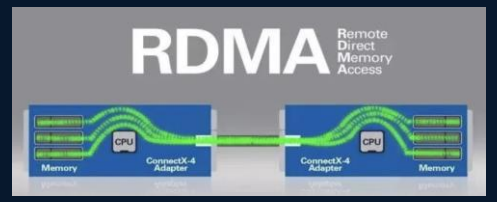

ECN/PFC

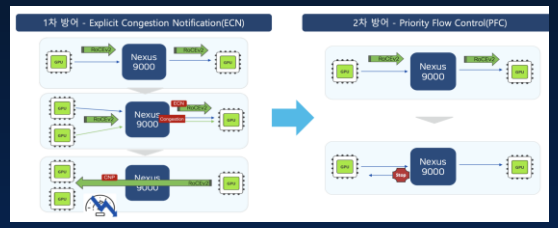

프로토콜적으로 레이턴시를 줄이고, 손실이 없는 네트워크를 구성

Advanced Load Balancing

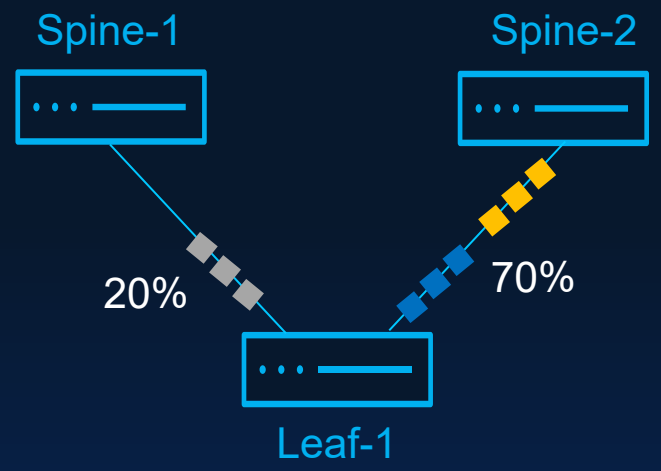

트래픽을 세밀하게 분산하고 실제 링크 부하를 기준으로 포워딩을 결정하여 가장 균일한 GPU 통신 성능을 제공

Secure AI Factory with NVIDIA

Available with Cisco & NVIDIA Enterprise and Cloud Partner Reference Architecture (RA)

NVIDIA Enterprise RA (ERA)

Cisco Cloud Partner RA (CRA)

NVIDIA Cloud Partner (NCP)

Nexus 9300 Switch with Cisco Silicon + Spectrum-X License

Cisco 9100 Switch with NVIDIA Spectrum Silicon

Nexus Dashboard

워크로드 가시성

토폴로지 기반 가시화

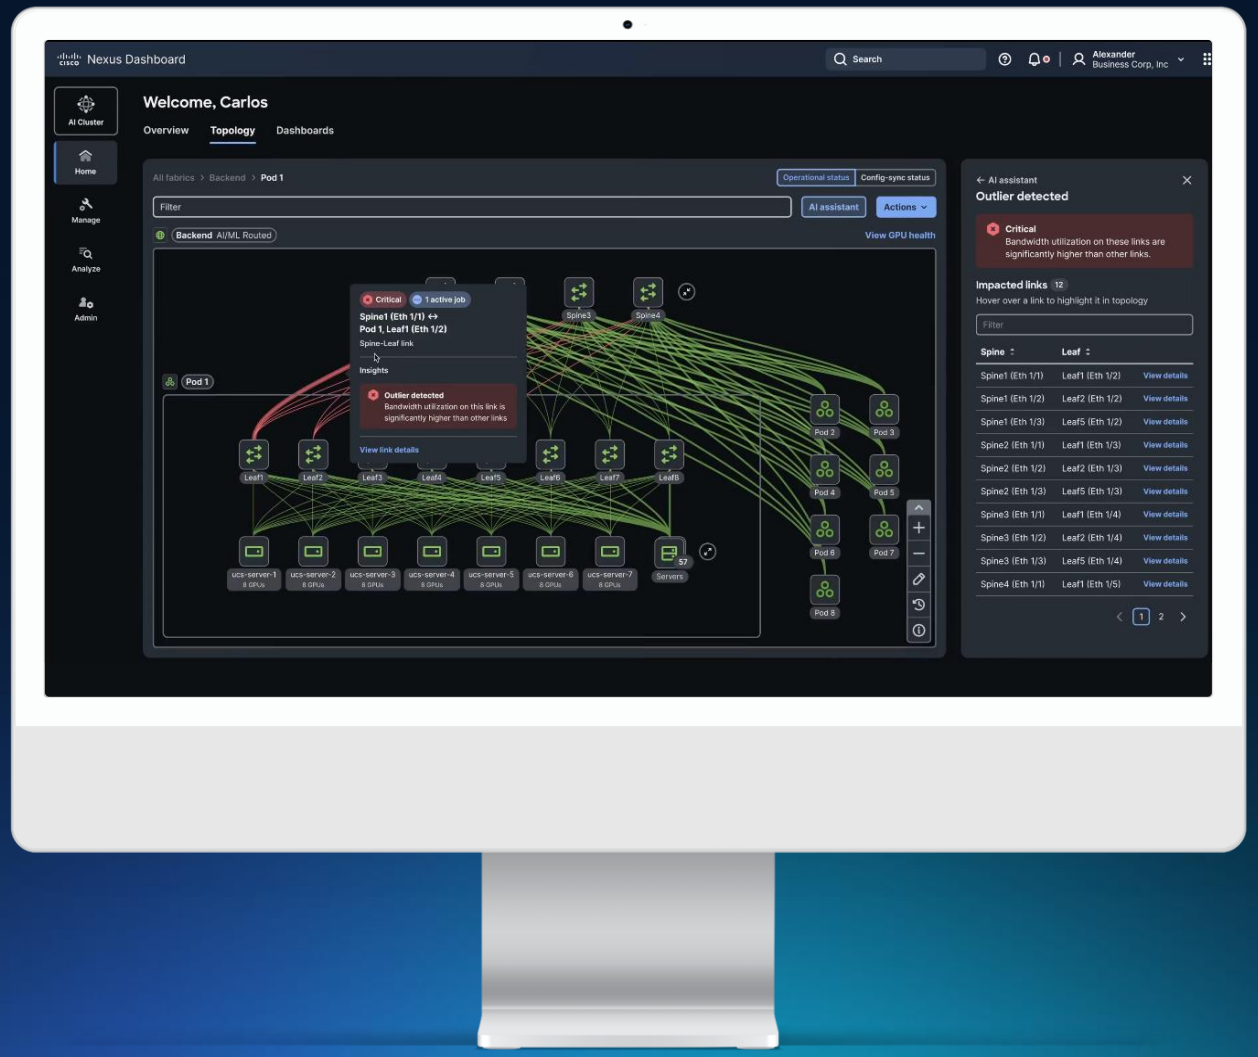

실시간 메트릭

선제적
트러블 슈팅 대응

Secure AI Factory with NVIDIA

Available with Cisco & NVIDIA Enterprise and Cloud Partner Reference Architecture (RA)

NVIDIA Enterprise RA (ERA)

Cisco Cloud Partner RA (CRA)

NVIDIA Cloud Partner (NCP)

Cisco 6000 Switch with Cisco Silicon + Spectrum-X License

Hyperfabric AI

Cloud Managed

Nexus 9300 Switch with Cisco Silicon + Spectrum-X License

Cisco 9100 Switch with NVIDIA Spectrum Silicon

Nexus Dashboard

On-Prem Managed

ETEVERS

IaaS, SaaS, PaaS,… NaaS?

- IaaS (Infrastructure As A Service) : 서버·스토리지·네트워크 같은 인프라 자원을 구독형으로 빌려 쓰는 모델로, 사용자는 OS와 애플리케이션을 직접 설치하고 운영한다.

- SaaS (Software As A Service) : 애플리케이션 실행 환경까지 포함된 플랫폼을 구독형으로 제공받아, 사용자는 서버 관리 없이 코드와 애플리케이션 개발에만 집중한다.

- PaaS (Platform As A Service) : 완성된 소프트웨어 자체를 구독형으로 사용하는 형태로, 사용자는 설치나 운영 없이 로그인만으로 서비스를 바로 이용한다.

…

NaaS?

Cisco Nexus Hyperfabric

Cloud Managed fabric option for Cisco AI PODs

AVAILBLE NOW

- 어디에 위치하든 온프레미스 네트워크 패브릭을 설계·구축·운영 가능
- 네트워크 전문 인력이 아니어도 IT 운영자, 애플리케이션 팀, DevOps 팀이 쉽게 사용할 수 있음
- 목적에 맞게 설계된 통합 스택을 기반으로 원하는 운영 결과를 제공

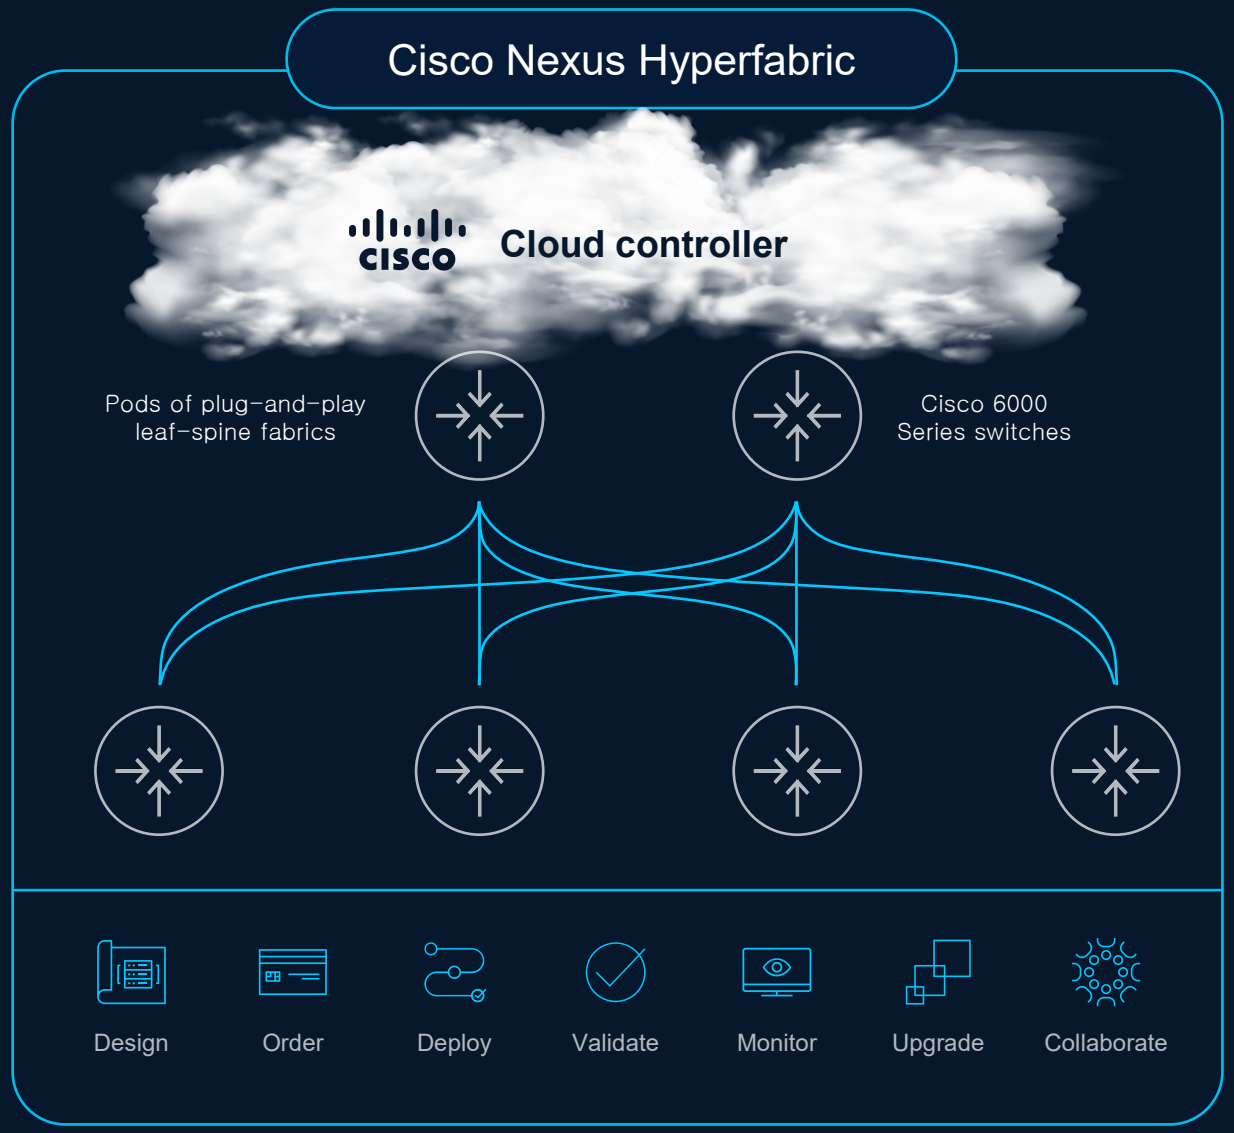

AI Pod

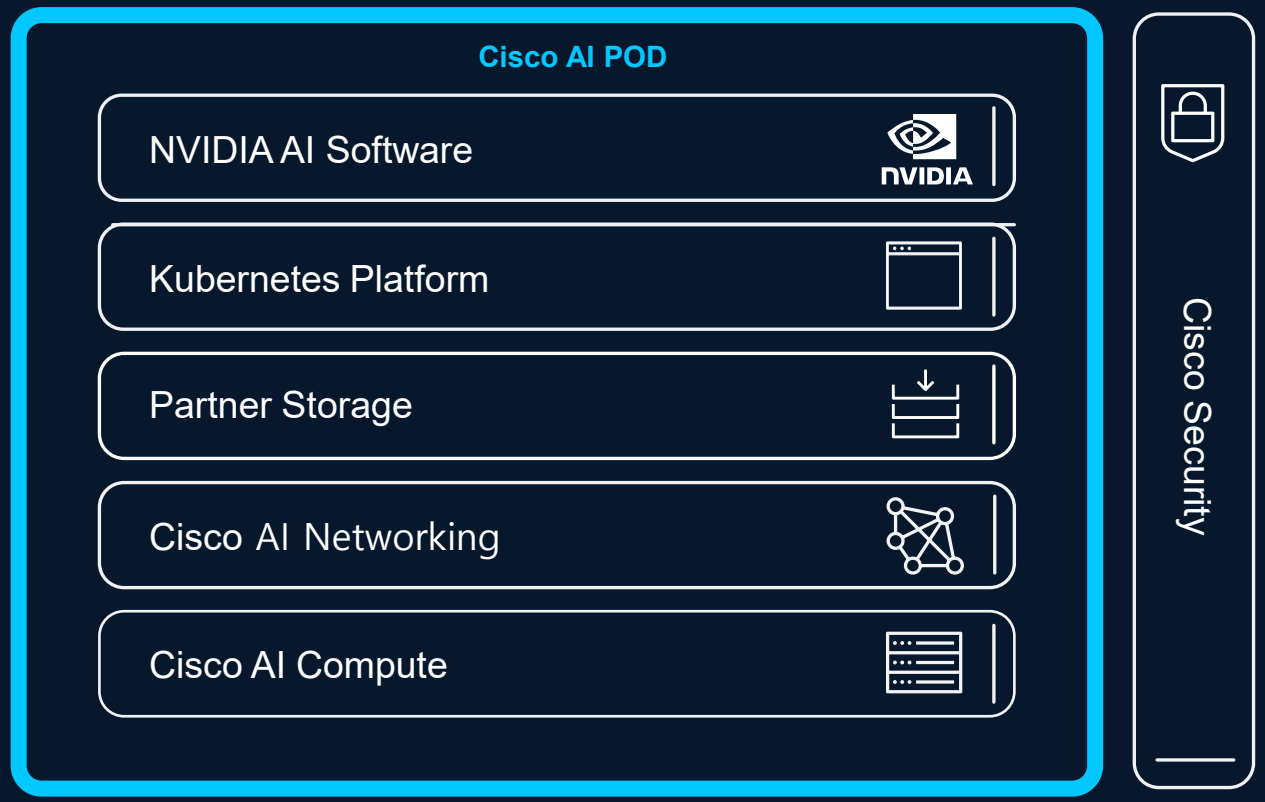
Cisco AI POD
NVIDIA AI Software
NVIDIA
Kubernetes Platform
Partner Storage
Cisco AI Networking
Cisco AI Compute
Cisco Security

Cisco AI PODs

어떤 AI 워크로드도 간단하고 효율적으로 지원하도록 설계된 확장 가능한 아키텍처

Deploy AI with confidence

Cisco CVD, NVIDIA ERA

Fully supported stack including Cisco and 3rd party components

Cisco CX Success Track

Orderable, use case driven AI-Ready infrastructure stacks

Inferencing. Optimization. Training.

Incremental, atomic-level -or- fabric-based cluster scale

Training | Optimization | Inferencing

Cisco AI PODs

EXTEND TO

CISCO® SECURITY

AI Defense

Hypershield

Firewall/Nexus® SmartSwitch

OBSERVABILITY

Observability Cloud

Open telemetry extensions

WORKLOAD MANAGEMENT & OPS

ISOVALENT | run:ai | slurm | splunk>

OPERATIONS

INTERSIGHT® & NEXUS DASHBOARD

AUTOMATION

AI SOFTWARE

NIM Operator
NeMo
CUDA

KUBERNETES: Red Hat OpenShift, ubuntu

ACCELERATED COMPUTE: UCS®

HIGH-PERFORMANCE NETWORKING: NEXUS

EXTEND TO STORAGE PLATFORM ECOSYSTEM: VAST, NetApp, PURE STORAGE, NUTANIX, HITACHI

ADVANCED SERVICES INCLUDED

Cisco Customer Experience

Cisco
Secure AI Factory

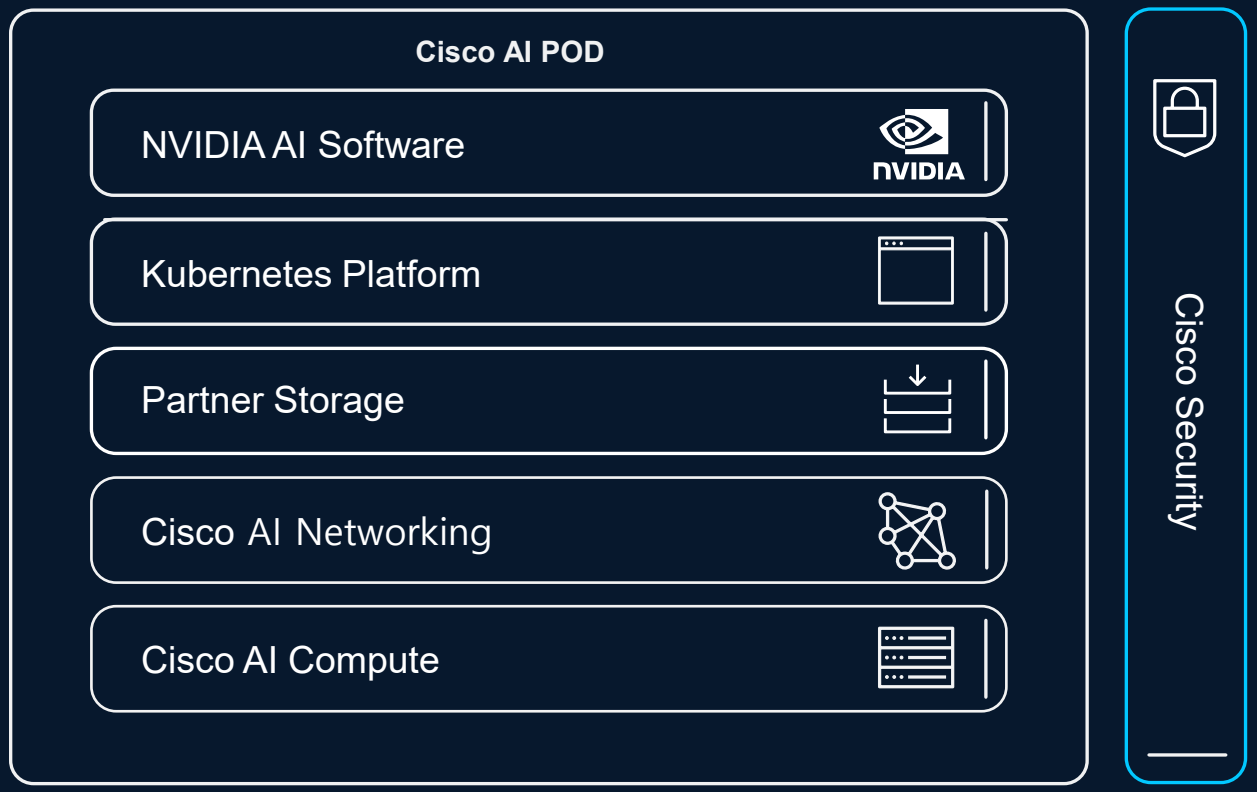

Cisco Secure AI Factory – 보안 영역

Cisco Security

AI 모델 & 애플리케이션 보안	Cisco AI Defense : 자체적으로 개발한 AI 모델 및 애플리케이션에 대한 테스트 및 런타임 보안 제공
워크로드 & 인프라 보안	Cisco Hypershield : 공격자의. 수평이동(lateral movement)를 차단하고, 패치 없이도 취약점을 사전 대응 단일 관리 인터페이스를 통해 통합운영 Cisco Live Protect : Cisco 네트워크 장비에 대한 인프라 보호 및 취약점 쉴드 적용
보안 운영 및 관제	Splunk Enterprise Security : 분석, 자동화, 인사이트를 통한 실시간 위협 탐지, 조사, 대응

AI 모델 & 애플리케이션 보안 – AI Defense

AI 모델 & 애플리케이션 검증 및 테스트

알고리즘 Red Teaming 을 통해 취약점 테스트

AI 애플리케이션 런타임 보호

악의적인 입력 프롬프트와 안전하지 않은 생성 결과를 차단하도록 가드레일 시행

AI 워크로드 & 인프라 보안 – Smart Switch & Live Protect

1 전통적인
Data Center보안의 한계

2 모든 스위치 포트를
Enforcement point로

3 지속적인 런타임 Defense

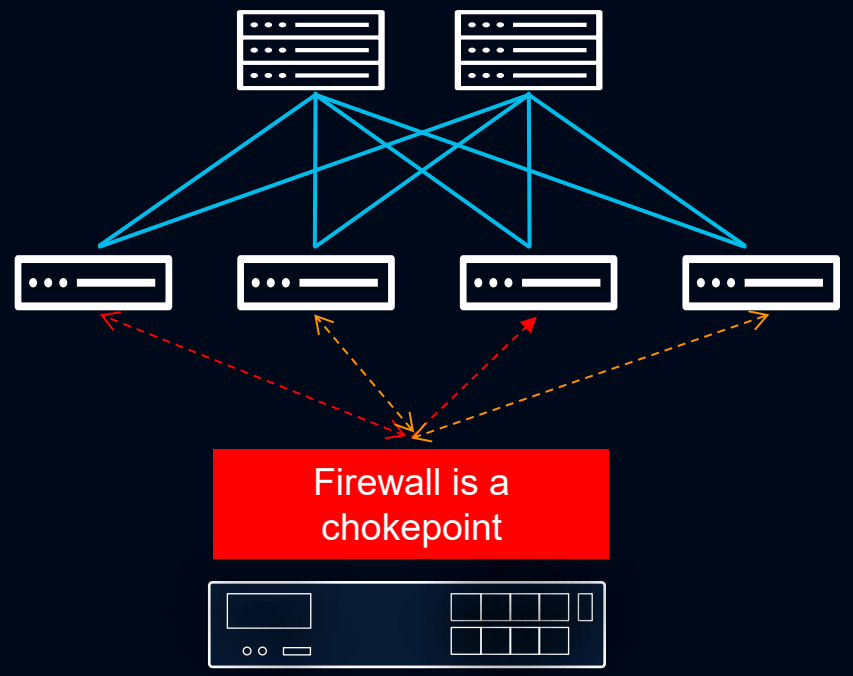

↑ Latency ↑ Cost ↑ Complexity

AI 워크로드 & 인프라 보안 – Smart Switch & Live Protect

1 전통적인
Data Center보안의 한계

2 모든 스위치 포트를
Enforcement point로

3 지속적인 런타임 Defense

Cisco Nexus Smart Switches
with Hypershield security

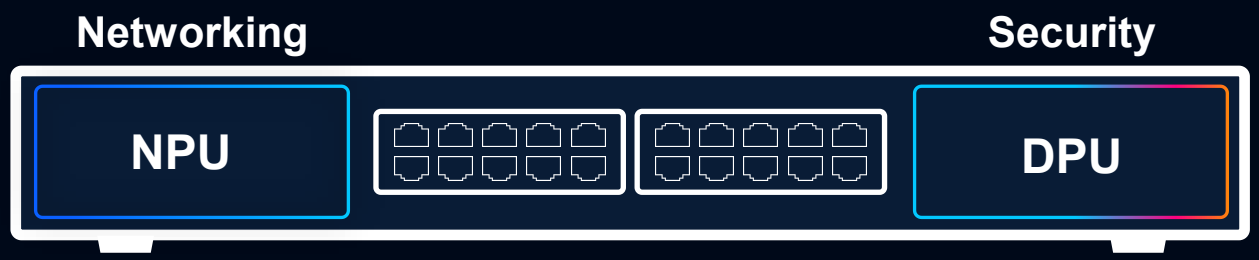

Eliminate External Firewall chokepoints

Security & Switching in One

800G Security Services with DPU

Unified network & security visibility

AI 워크로드 & 인프라 보안 – Smart Switch & Live Protect

1 전통적인
Data Center보안의 한계

2 모든 스위치 포트를
Enforcement point로

3 지속적인 런타임 Defense

Vulnerability shielding for Cisco Nexus

No PSIRT patching or OS upgrade | No downtime or switch reboot | Continuous re-validation

Summary

Cisco가 검증한 고객이 쉽게 빠르게 배포하고 쉽게 운용

Cisco AI PODs

NVIDIA AI Enterprise | **NeMo** | **NIM** | **Blueprints**

NVIDIA Run:ai | **AI Workload & GPU Orchestration**

Kubernetes platform — Options: Red Hat OpenShift, Nutanix NKP, Upstream Kubernetes

Partner — Options: NetApp, Pure Storage, VAST Data, Hitachi Vantara, Nutanix NUS

AI Networking — Cisco Data Center Switching Options for Network Management: Nexus Dashboard or Nexus Hyperfabric | **NVIDIA Partnership**

Cisco Compute — Options: NVIDIA HGX, MGX or RTX PRO based UCS Servers NVIDIA BlueField® DPUs | Managed with Cisco Intersight®

다양한 고객의 요구사항에 맞는 AI 서버 포트폴리오

AI Security

Cisco AI Defense

Splunk Enterprise Security

NVIDIA와의 Partnership

AI Observability

Splunk Observability

AI 보안까지 고려한 Secure AI Factory

감사합니다.

ETEVERS